



**UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE**  
**UNIDADE ESPECIALIZADA EM CIÊNCIAS AGRÁRIAS**  
**CURSO SUPERIOR DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE**  
**SISTEMAS**

**ELIDIEL DANTAS DA COSTA**

**DESENVOLVIMENTO DE APLICAÇÃO COMPUTACIONAL PARA DETECÇÃO E**  
**CONTAGEM DE OVOS DO AEDES AEGYPTI UTILIZANDO PROCESSAMENTO**  
**DIGITAL DE IMAGENS E LÓGICA FUZZY.**

**Macaíba**

**2017**

**ELIDIEL DANTAS DA COSTA**

**DESENVOLVIMENTO DE APLICAÇÃO COMPUTACIONAL PARA DETECÇÃO E  
CONTAGEM DE OVOS DO AEDES AEGYPTI UTILIZANDO PROCESSAMENTO  
DIGITAL DE IMAGENS E LÓGICA FUZZY.**

Trabalho de conclusão de curso de graduação  
apresentado à Unidade Especializada em Ciências  
Agrárias da Universidade Federal do Rio Grande  
do Norte como requisito parcial para a obtenção do  
título de Tecnólogo em Análise e  
Desenvolvimento de Sistemas.

Orientadora: Prof<sup>a</sup>. Dr<sup>a</sup>. Alessandra Mendes  
Pacheco Guerra Vale

Coorientadora: Prof<sup>a</sup>. Dr<sup>a</sup>. Laura Emmanuella  
Alves dos Santos Santana de Oliveira

Macaíba

2017

Universidade Federal do Rio Grande do Norte - UFRN

Sistema de Bibliotecas - SISBI

Catálogo de Publicação na Fonte. UFRN - Biblioteca Setorial Prof. Rodolfo Helinski - Escola Agrícola de Jundiaí -

Costa, Elidiel Dantas da.

Desenvolvimento de aplicação computacional para detecção e contagem de ovos do Aedes Aegypti utilizando processamento digital de imagens e lógica Fuzzy / Elidiel Dantas da Costa. - 2017.

54f.: il.

Monografia (Tecnólogo) Universidade Federal do Rio Grande do Norte. Unidade Acadêmica Especializada em Ciências Agrárias. Tecnólogo em Análise e Desenvolvimento de Sistemas. Macaíba, 2017.

Orientador: Alessandra Mendes Pacheco Guerra Vale.

Coorientador: Laura Emmanuella Alves dos Santos Santana de Oliveira.

1. Processamento digital de imagem - Monografia. 2. Sistema de inferência Fuzzy - Monografia. 3. Aedes aegypti. -

ELIDIEL DANTAS DA COSTA

**DESENVOLVIMENTO DE APLICAÇÃO COMPUTACIONAL PARA DETECÇÃO E  
CONTAGEM DE OVOS DO AEDES AEGYPTI UTILIZANDO PROCESSAMENTO  
DIGITAL DE IMAGENS E LÓGICA FUZZY.**

Trabalho de conclusão de curso de graduação apresentado à Unidade Especializada em Ciências Agrárias da Universidade Federal do Rio Grande do Norte como requisito parcial para a obtenção do título de Tecnólogo em Análise e Desenvolvimento de Sistemas.

Aprovado em: \_\_\_\_ de \_\_\_\_\_ de \_\_\_\_.

**BANCA EXAMINADORA**

---

Prof<sup>a</sup>. Dr<sup>a</sup>. Alessandra Mendes Pacheco Guerra Vale - UFRN (orientadora)

---

Prof<sup>a</sup>. Dr<sup>a</sup>. Laura Emmanuella Alves dos Santos Santana de Oliveira - UFRN (Coorientadora)

---

Prof. Dr. Márcio Dias Pereira –UFRN (Membro Interno)

---

Prof. Ms. Emerson Moura de Alencar –UFRN (Membro Interno)

## RESUMO

O *Aedes aegypti* é o vetor transmissor de várias doenças virais, incluindo dengue, zica e chincungunha. Estima-se que 50 milhões de pessoas sejam infectadas anualmente e que aproximadamente 2,5 bilhões morem em países onde essas doenças são endêmicas. Uma das formas de prevenção é o controle do vetor transmissor. Tal controle é realizado atualmente a partir de indicativos do Sistema de Informação de Agravos (Sinan) das notificações das doenças transmitida pelo Aedes. Dada a importância da tecnologia no controle de epidemias, este trabalho propõe um modelo de sistema computacional que, através das imagens de oviposição, calcule a quantidade de ovos presente nessas armadilhas, e utilize esses dados como de indicativos da presença do Aedes em cada área da cidade. Para este fim foram utilizadas imagens das áreas georreferenciadas, e um Sistema de Inferência Fuzzy (SIF). Para verificação do método proposto foram analisadas 206 imagens de oviposição e os resultados obtidos foram acurácia de 98,94% e Coeficiente de correlação de Matthews de 0,9 para classificação e contagem dos ovos quando comparados a contagem manual. Assim, a utilização do modelo auxiliará nas tomadas de decisões quanto a prevenção e controle das doenças deste vetor transmissor.

**Palavras-chave:** Processamento digital de imagem, Sistema de inferência Fuzzy, *Aedes aegypti*.

## **ABSTRACT**

*Aedes aegypti* is the transmitter vector of several viral diseases, including dengue, zica and chincungunha. It is estimated that 50 million people are infected annually and that approximately 2.5 billion live in countries where these diseases are endemic. One of the forms of prevention is the control of the transmitting vector. Such control is currently carried out using indicatives from the Avian Disease Information System (Sinan) of Aedes' disease notifications. Given the importance of technology in the control of epidemics, this work proposes a model of a computer system that, through oviposition images, calculates the amount of eggs present in these traps, and use these data as indicative of the presence of Aedes in each area of the City. For this purpose, we used images from the georeferenced areas, and a Fuzzy Inference System (SIF). To verify the proposed method, 206 oviposition images were analyzed and the results obtained were 98.94% accuracy and Matthews correlation coefficient of 0.9 for classification and counting of eggs when the manual counting was purchased. Thus, the use of the model will aid in decision making regarding the prevention and control of the diseases of this vector transmitter..

**Keywords:** Digital image processing, Fuzzy inference system, *Aedes aegypti*.

## SUMÁRIO

1	Introdução .....	11
1.1	Justificativa .....	12
1.2	Objetivos .....	12
1.2.1	Objetivo geral.....	12
1.2.2	Objetivos específicos .....	12
1.3	Organização do trabalho .....	13
2	Referencial Teórico .....	13
2.1	Abordagens para detecção e contagem utilizando processamento digital de imagens ...	14
2.2	Abordagens para descrição e classificação utilizando lógica <i>Fuzzy</i> associada às técnicas de processamento digital de imagens .....	15
2.3	Trabalhos relacionados à classificação e contagem de ovos do <i>Aedes aegypti</i> em imagens digitais .....	16
2.4	Imagens Digitais.....	18
2.4.1	Processamento Digital de Imagens .....	20
2.4.2	Aquisição de Imagens .....	21
2.4.3	Pré-processamento .....	21
2.4.4	Segmentação .....	21
2.4.5	Representação e Descrição.....	22
2.4.6	Reconhecimento e Interpretação .....	22
2.4.7	Base de conhecimento.....	22
2.5	Lógica Fuzzy .....	22
2.5.1	Os conjuntos Fuzzy .....	23
2.5.2	Variáveis Linguísticas .....	24
2.5.3	Funções de pertinência.....	25
2.5.4	Regras linguísticas .....	25
2.5.5	Sistema de Inferência Fuzzy .....	26
3	Apresentação das técnicas e etapas desenvolvidas .....	29
3.1	Contextualização .....	29
3.2	Processamento digital de imagens .....	30
3.2.1	Aquisição de imagens .....	30

3.2.2	Pré-processamento .....	31
3.2.3	Segmentação .....	32
3.2.4	Representação e descrição.....	33
3.3	Sistema de Inferência <i>Fuzzy</i> .....	35
3.4	Processo de Fuzzificação .....	36
3.5	Variáveis de saída .....	37
3.6	Implementações das regras Fuzzy.....	38
3.7	Processo de Defuzzificação.....	38
4	Análise de resultados.....	40
4.1	Experimentos.....	40
4.2	Resultados .....	42
4.3	Discussões .....	44
4.3.1	Segmentação .....	44
4.3.2	Classificação e contagem .....	47
5	Conclusão.....	48
5.1	Conclusões .....	48
5.2	Trabalhos Futuros .....	49
6	Referências.....	50
6.1	Apêndice .....	52



## LISTA DE FIGURAS

Figura 1: Uma imagem monocromática e a convenção utilizada para o par de eixos (x,y).....	18
Figura 2: Representações do Modelo RGB (Gonzalez & Woods, 2009).....	19
Figura 3: Máscaras espaciais para imagens RGB (Gonzalez & Woods, 2009). ....	19
Figura 4: Representações de uma imagem: a) cores (modelo RGB), b) escalas de cinza, c) preto e branco, d) componente R, e) componente G, f) componente B. Imagem: Lena.jpg (Gonzalez & Woods, 2000). ....	20
Figura 5: Diagrama do Proc. Digital de Imagens (Gonzalez, Woods, 2000).....	21
Figura 6: Conjunto Fuzzy.....	24
Figura 7: Lógica Fuzzy .....	24
Figura 8: Exemplo de função de pertinência.....	25
Figura 9: Sistema de Inferência Fuzzy (Adaptado de Leite, 2009).....	27
Figura 10: Diagrama do Proc. Digital de Imagens (Gonzalez, Woods, 2000)b.....	30
Figura 11: Modelo de armadilha de oviposição .....	31
Figura 12: Pré-processamento.....	32
Figura 13: Segmentação de imagem com ovos .....	33
Figura 14 Descritor de área .....	33
Figura 15 Descritor de convexidade.....	34
Figura 16 Descritor de forma .....	34
Figura 17 Descritor de diâmetro.....	34
Figura 18 Descritor de perímetro .....	35
Figura 19 Modelo de fuzzyzificação das variáveis linguísticas .....	36
Figura 20 Exemplo de função trapezoidal para variável linguística Diâmetro .....	37
Figura 21: Saída do SIF.....	38
Figura 22: Classificação do sistema de inferência. ....	39
Figura 23: Tela inicial Seleção e processamento das imagens.....	41
Figura 24: Resultado da classificação e contagem dos objetos das imagens. ....	42
Figura 25: Imagem segmenta Identificação de falsos positivos. ....	45
Figura 26: Resultado da classificação do sistema para falso positivo.....	45
Figura 27: Falso Negativo: ovos colados. ....	46
Figura 28: Classificação de objetos como falso negativo. ....	46
Figura 29: Os valores do Gold Standards estão em porcentagem(%) .....	47
Figura 30 Amostra 1: Imagem com quatro ovos.....	52
Figura 31 Amostra 2: Imagem com três ovos .....	52
Figura 32 Amostra 3: Imagem com dez ovos.....	53
Figura 33 Amostra 4: Imagem com dez ovos.....	53
Figura 34 Amostra 5:Imagem com quatro ovos.....	54

## **LISTA DE TABELAS**

Tabela 1: Variáveis Linguísticas	35
Tabela 2: Exemplo de base de dados	36
Tabela 3: Matriz de Confusão	43
Tabela 4: Resultados da classificação do Sistema	43
Tabela 5: Resultado da Classificação e Contagem do Sistema	44

## 1 Introdução

O *Aedes aegypti* é o vetor transmissor de várias doenças virais, como dengue, febre amarela, chikungunya e zika. É estimado que 50 milhões de infecções por dengue ocorram anualmente e que aproximadamente 2,5 bilhões de pessoas morram em países onde a dengue é endêmica. Em Natal, a média anual é de 835 casos notificados por 100 mil habitantes, a quantidade está bem acima do que preconiza a Organização Mundial de Saúde (OMS), que avalia como epidemia acima de 300 casos para cada grupo de 100 mil habitantes (SMS, 2015). No ano de 2015 foram notificados 7329 casos de dengue na cidade segundo dados da Secretaria Municipal de Saúde Natal (SMS, 2015).

Uma das formas de prevenir estas doenças é controlando o vetor transmissor. Atualmente na cidade de Natal/RN este controle é realizado por indicativos de georreferenciamento das áreas endêmicas. O georreferenciamento é uma forma de identificar em um mapa, determinado local a partir de suas coordenadas geográficas. Este processo inicia-se com a obtenção das coordenadas de pontos do mapa a serem georreferenciadas, conhecidos como pontos de controle, nestes pontos são colocadas armadilhas para captura de ovos do mosquito, estas armadilhas são comumente conhecidas como ovitrampas ou armadilhas de oviposição (COMUNITOR, 2016).

As armadilhas de oviposição atraem fêmeas em busca de sítios de postura, embora capture ovos e não as fêmeas (FIOCRUZ, 2014). Usada desde 1965 em pesquisa em diversos países, a oviposição utiliza vasos de plantas pretos com infusão à base de feno para atrair os mosquitos fêmea, que buscam locais para pôr seus ovos (FIOCRUZ, 2014).

Atualmente são instaladas armadilhas de oviposição nos pontos de controle na cidade de Natal, esses pontos são georeferenciados e colocados a um raio de 300 metros de um para outro dentro das áreas de atuação da vigilância em saúde, objetivando identificar a população do mosquito *Aedes aegypti*. Dessa forma, os pontos de infestação do mosquito possuem uma localização exata, servindo de referência para o direcionamento de ações específicas de combate ao mosquito de acordo com o nível de infestação de cada local.

As contagens dos ovos presentes nas armadilhas são realizadas manualmente pelos agentes do Centro de Controle de Zoonoses (CCZ) da cidade de Natal-RN, o que demanda uma quantidade significativa de pessoal e tempo para a realização dessa atividade. Nestas circunstâncias, a publicação dos dados referentes a estas contagens é feita em um período equivalente a uma semana, retardando o trabalho de efetiva ação na área endêmica. A execução deste processo envolvendo um número menor de pessoas e em um prazo mais curto poderá

trazer benefícios para a identificação das áreas críticas e tomadas de decisões quanto às ações de prevenção e/ou combate ao mosquito.

Etimologicamente a palavra previsão sugere que se quer ver uma coisa antes que ela exista, diante disso, este trabalho propõe um modelo de sistema computacional automático capaz de realizar previsão semanal das áreas de maior incidência do mosquito *Aedes*, através da quantidade de ovos do mosquito encontrados nas armadilhas. Índice de Positividade (IPO) e Índice de Densidade de Ovos (IDO) nas áreas georreferenciadas da cidade de Natal, com uso das técnicas de Processamento Digital de Imagem (PDI) e Sistema de Inferência Fuzzy (SIF). Este modelo deverá diagnosticar a maior incidência do mosquito em determinada área e indicar a necessidade de ações emergenciais voltadas ao combate e controle, antes do adoecimento dos habitantes da área citada, ao invés de gerar um raio de atuação de combate da área somente ao ser notificado o adoecimento de algum habitante dessa localidade, assim como ocorre atualmente na cidade.

## **1.1 Justificativa**

As doenças transmitidas pelo mosquito *Aedes aegypti* geram graves problemas de saúde pública, não somente no Rio Grande do Norte, mas em todo o país, desta forma, são essenciais as medidas que possam prevenir epidemias relacionadas a essas doenças. Para tanto, é necessário prever com certa antecedência ou em um estágio inicial, a incidência das mesmas (Santos, 2013). Portanto este trabalho propõe o desenvolvimento de um sistema computacional, que realize a contagem automática dos ovos do *Aedes*, possibilitando que medidas de prevenção e controle sejam tomadas com antecedência a uma epidemia.

## **1.2 Objetivos**

Neste tópico serão abordados os objetivos gerais e específicos.

### **1.2.1 Objetivo geral**

O objetivo deste trabalho é desenvolver um sistema automatizado capaz de identificar e contar ovos do mosquito *Aedes aegypti* em imagens provenientes de armadilhas de oviposição.

### **1.2.2 Objetivos específicos**

- Adquirir e disponibilizar um banco de imagens de ovos provenientes de armadilhas de oviposição;

- Observar características que identificam ovos do *Aedes Aegypti* nas armadilhas de oviposição.

### 1.3 Organização do trabalho

Este trabalho está organizado em 5 capítulos:

- O Capítulo 2 apresenta o Referencial teórico;
- O Capítulo 3 apresenta as técnicas desenvolvidas para realização do trabalho;
- O Capítulo 4 apresenta os resultados;
- O Capítulo 5 expõe as conclusões e perspectivas futuras.

## 2 Referencial Teórico

Neste capítulo é apresentado o referencial teórico relacionado ao foco principal deste trabalho envolvendo especialmente a análise e soluções de problemas de contagem e classificação, e o referencial teórico.

- **Abordagens para detecção e contagem utilizando processamento digital de imagens:** apresenta trabalhos relacionados às soluções que utilizam técnicas de processamento digital de imagens para identificação, segmentação e contagem de elementos diversos em imagens digitais.
- **Abordagens para descrição e classificação utilizando lógica *fuzzy* associada às técnicas de processamento digital de imagens:** apresenta trabalhos relacionados às soluções para os problemas de descrição e classificação de elementos de grupos distintos em imagens digitais.
- **Trabalhos relacionados à classificação e contagem de ovos do *Aedes aegypti* em imagens digitais:** apresenta trabalhos que utilizaram técnicas de processamento digital de imagens, associadas ou não a outras abordagens, especificamente para a detecção e contagem de ovos do *Aedes aegypti*.
- **Imagens Digitais e Processamento digital de imagens:** apresentam conceitos de imagens digitais, processamento digital de imagens e etapas constituintes, aquisição, pré-processamento, segmentação e classificação.
- **Lógica *fuzzy*:** Apresenta os conceitos de lógica *fuzzy* relevantes para este trabalho, como variáveis linguísticas, funções de inferência e sistema de inferência *fuzzy*.

## **2.1 Abordagens para detecção e contagem utilizando processamento digital de imagens**

Nesta seção são apresentados alguns trabalhos encontrados na literatura que usam PDI para detecção e contagem de objetos.

O trabalho apresentado por Santos (2009) apresenta o desenvolvimento de um sistema de reconhecimento de padrões de plantas invasoras e percentuais de ocupação de folhas largas e folhas estreitas, em sistema de produção agrícola, utilizando técnicas de processamento digital de imagens. Para o desenvolvimento houve a consideração das etapas de aquisição das imagens, pré-processamento, segmentação baseada em textura, descritores para reconhecimento das plantas invasoras e percentual de ocupação de cada tipo de planta. Este trabalho obteve como resultado uma taxa de 84,24% no reconhecimento em ambiente de campo para folhas largas e 80,17% para folhas estreitas.

Em Silva (2014) é apresentado um sistema automático para contagem de telhas utilizando processamento digital de imagens em dispositivos móveis. O sistema recebe como entrada imagens gravadas pelo dispositivo e calcula a quantidade total de telhas presente na gravação. O trabalho obteve como resultado uma taxa de acerto de 98,1% na contagem das telhas.

Feitosa (2012) propõe um método para contagem volumétrica de veículo que utiliza visão computacional e processamento digital de imagem, sua execução é destinada a dispositivos móveis. Esses dados têm como objetivo auxiliar no planejamento de tráfego urbano. O método obteve como resultado médio de 80% de acerto na contagem dos veículos.

Carone et.al (2012) apresenta o desenvolvimento de um sistema de software para contagem automática de pessoas em tempo real, baseado em técnicas de processamento e análise de imagens capturadas por dispositivos móveis. A metodologia desenvolvida nesse trabalho é baseada exclusivamente na análise das imagens obtidas por câmeras de vídeo instaladas na cena de interesse. Especificamente, o sistema projetado neste trabalho foi concebido para operar de forma distribuída e embarcada em plataformas móveis ou nós sensores, tais como smartphones, configurando ao sistema características inovadoras que potencializam sua aplicação em diversos cenários. O sistema desenvolvido foi validado com sucesso em cenários desafiadores, tais como cenas com várias pessoas e cenas com variação de luminosidade, atingindo uma taxa média de acerto de 94,10%.

Ferreira (2012) propões uma arquitetura de hardware para detecção de objetos em movimento baseada no algoritmo de subtração de fundo, sendo implementado em FPGAs (Field Programmable Gate Arrays). Para alcançar isto, foi aplicada técnicas de processamento digital

de imagens executadas nos seguintes passos: (a) a imagem de fundo (em nível de cinza) é armazenada em uma memória SRAM externa, (b) é aplicada uma etapa de filtragem passa-baixa nas imagens de fundo e no quadro atual, (c) é realizada a operação de subtração entre as duas imagens, e (d) é aplicada um filtro morfológico sobre a imagem resultante. Posteriormente é calculado o centro de gravidade do objeto para ser enviado para um computador. O sistema obteve como resultado um incremento na velocidade de processamento de 32 vezes maior em comparação com a implementação da mesma arquitetura rodando em plataforma software.

Em Dias (2014) apresenta o desenvolvimento de um método para detecção de áreas alagadas da bacia do Médio Araguaia. Para tanto foram utilizadas técnicas de sensoriamento remoto aplicadas a imagens multitemporais do sensor TM do satélite LANDSAT 5, onde, através dos índices gerados pela transformação Tasseled Cap (TC), foram extraídas as amostras de treinamento que permitiram realizar uma classificação supervisionada através do algoritmo *Support Vector Machine* (SVM). Esses procedimentos permitiram delinear os limites máximos das áreas passíveis de inundação em época de cheia, que recobrem uma extensão de 88.119 km<sup>2</sup>, cerca de 23% da área total da bacia do Médio Araguaia.

## **2.2 Abordagens para descrição e classificação utilizando lógica *Fuzzy* associada às técnicas de processamento digital de imagens**

Vale (2014) utiliza técnicas de processamento digital de imagens associada a uma abordagem *fuzzy* genérica e automática, apresenta dois Sistemas de Inferência *Fuzzy*, para a segmentação automática de componentes sanguíneos e classificação diferencial de leucócitos, respectivamente, em imagens microscópicas de esfregaços. Este trabalho apresenta um percentual de acurácia na técnica de segmentação desenvolvida de 97,31%, para leucócitos, 95,39% para eritrócitos e 95,06% para plasma sanguíneo. Quanto à classificação diferencial de leucócitos, os percentuais variam entre 92,98% e 98,39% para diferentes tipos de leucocitários.

Boaventura (2010) apresenta uma abordagem, baseada no conceito de número *fuzzy*, para detecção de bordas em imagens digitais chamado de FUNED (*Fuzzy Number Eddge Detector*). Esta técnica de detecção de bordas implementadas considera uma vizinhança local dos pixels da imagem definida pelo usuário e, baseado no conceito de número *fuzzy*, é verificado se um pixel pertence ou não aquela região da imagem, com base na intensidade dos tons de cinza que compõe a região.

Andrade (2014) propõe o desenvolvimento dos operadores morfológicos *fuzzy* utilizando as R-implicações para auxiliar e aperfeiçoar o processamento de imagens e, em seguida, a construção de um sistema para contar esporos de fungos micorrízicos e de células

sanguíneas vermelhas. O sistema apresentou como resultado 75% de acertos em relação à contagem das células a olho nu.

Lucas (2014) apresenta um conjunto de métodos para avaliação, quantificação e classificação das imagens por Ressonância Magnética através de um processo automatizado. Para a etapa de segmentação foi usado *Fuzzy c-means* e *Watersheds*, para classificação redes neurais e método de Bayes. Este trabalho apresentou como resultado, no método de Bayes 68% na classificação das imagens e redes neurais 100% na classificação.

Souza (2011) propõe uma metodologia para a automação da análise morfológica de imagens de cromossomos humanos irradiados no reator nuclear IEA-R1 e, portanto, sujeitos a aberrações morfológicas. Esta metodologia se propõe a auxiliar na identificação, caracterização e classificação de cromossomos pelo profissional citogeneticista. O desenvolvimento da metodologia inclui a elaboração de um aplicativo baseado em técnicas de inteligência artificial utilizando Lógica *Fuzzy* e técnicas de processamento de imagens. Este trabalho obteve como resultado acerto no reconhecimento das imagens cromossômicas de 93,9%.

### **2.3 Trabalhos relacionados à classificação e contagem de ovos do *Aedes aegypti* em imagens digitais**

Alguns estudos envolvendo o processamento digital de imagens na contagem de ovos do *Aedes aegypti* são encontrados na literatura.

No trabalho exposto por Portela (2009), foi proposto um método automático de detecção e contagem de ovos de *Aedes aegypti* em imagens de ovitrampas usando técnicas de processamento digital de imagens e reconhecimento de padrões. Foram utilizados algoritmos de limiarização (algoritmo de Lilee, algoritmo de Huang), de agrupamento de dados (algoritmo KMeans), mudanças de sistemas de cores e programação evolucionária. Este trabalho apresentou os seguintes resultados: no primeiro método, erro médio na contagem dos ovos de 10,39%, no segundo método 15,16%, no terceiro método 43,93%, no quarto método 46,87% e no quinto método 43,92%.

Feitosa (2015) propôs desenvolver dois métodos de contagem automática dos ovos do *Aedes aegypti* utilizando técnicas de processamento de imagens. O primeiro método consiste em explorar o modelo de cor RGB, limiarização de Otsu e realização de filtragem. O segundo método explora o modelo de cor  $L^*a^*b^*$ , utilizou o algoritmo k-means. O primeiro método obteve média de erro na contagem dos ovos de 23,94% e segundo método obteve média de erro de 18,12%.



Os trabalhos mencionados usam um método de contagem dos ovos do *Aedes* que consiste em, após as etapas de pré-processamento e segmentação, calcular o total de pixels brancos presente na imagem dividida pela área média. Entretanto, mesmo considerando os resultados positivos obtidos, algumas limitações foram observadas: i) no trabalho de Portela (2009) o processo de segmentação apresenta problemas devido à técnica utilizada onde o processo de segmentação é propício a criar segmentos contendo manchas que atrapalham na contagem dos ovos. Além disso, também apresenta dificuldade na identificação dos verdadeiros negativos, ou seja, objetos que não são ovos; ii) no trabalho de Feitosa (2015) apresenta dificuldade na aplicação e validação das técnicas proposta devido a falta de um banco de imagens das armadilhas de ovitrampa.

As técnicas desenvolvidas neste trabalho apresentam um método automático de segmentação e classificação e contagem dos ovos do *Aedes* nas armadilhas de oviposição, a combinação da lógica *fuzzy* com as técnicas de processamento digital de imagens possibilitou um melhor refinamento do processo de segmentação e classificação dos ovos do *Aedes*, como descrito da seção 4 deste trabalho.

Com o objetivo de abordar as limitações encontradas na literatura, os seguintes aspectos foram considerados: i) Nas etapas de pré-processamento e segmentação os objetos encontrados nas palhetas de oviposição são separados individualmente; ii) Definição de novos descritores que facilitem a classificação dos objetos ovos e não ovos; iii) As etapas de classificação e contagem dos ovos é realizada através do SIF; iv) Definição de um banco de imagens.

## 2.4 Imagens Digitais

Imagem (do latim imago) significa a representação visual de um objeto. Para fins computacionais, a imagem é uma representação em 2 dimensões de um objeto como um conjunto finito de valores digitais inteiros, onde cada valor é chamado de *picture element*, ou pixel. Assim sendo, uma imagem digital pode ser definida como uma função bidimensional,  $f(x,y)$ , onde  $x$  e  $y$  são coordenadas espaciais e a amplitude de  $f$  para qualquer par de coordenadas  $(x,y)$  é chamada de intensidade ou nível de cinza da imagem para aquele ponto. Quando  $x$ ,  $y$  e o valor de intensidade  $f$  são finitos e discretos essa imagem pode ser chamada de imagem digital. (Portela, 2009).

Uma imagem digital também pode ser representada em forma de uma matriz bidimensional  $M \times N$ . Nesta matriz, cada elemento  $f(x,y)$ ,  $x = 0, 1, \dots, M-1$  e  $y = 0, 1, \dots, N-1$  é chamado pixel. Dizemos então que a imagem tem dimensão  $M$  pixel na horizontal (eixo  $x$ ) e  $N$  pixel na vertical (eixo  $y$ ).

Uma imagem monocromática pode ser descrita matematicamente por uma função  $f(x,y)$  da intensidade luminosa, sendo seu valor, em qualquer ponto de coordenadas espaciais  $(x,y)$ , proporcional ao brilho (ou nível de cinza) da imagem naquele ponto. A Figura 1 mostra uma imagem monocromática e a convenção utilizada neste livro para o par de eixos  $(x,y)$  (Filho; Neto, 1999).



Figura 1: Uma imagem monocromática e a convenção utilizada para o par de eixos  $(x,y)$

Uma imagem colorida é uma imagem multispectral, em que a cor em cada ponto  $(x,y)$  é definida por meio de três grandezas: luminância, matiz e saturação. A luminância está associada com o brilho da luz, o matiz com o comprimento de onda dominante e a saturação

com o grau de pureza (ou intensidade) do matiz. A maioria das cores visíveis pelo olho humano pode ser representada como uma combinação de bandas das três cores primárias vermelho (R, red), verde (G, green) e azul (B, blue), (Figura 2).

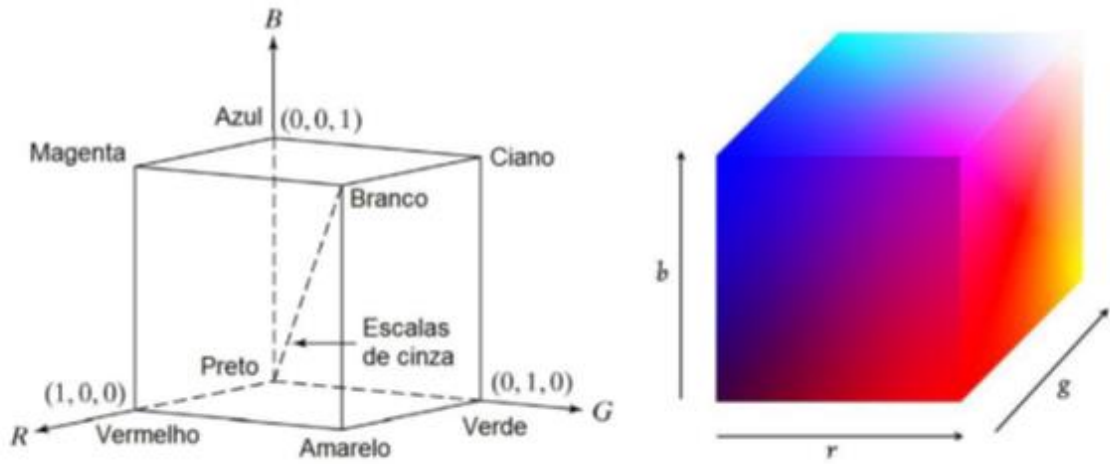


Figura 2: Representações do Modelo RGB (Gonzalez & Woods, 2009).

As imagens representadas no espaço RGB consistem em arranjos de  $x \times y \times 3$  pixels, onde cada pixel é uma tripla correspondente às cores vermelho, verde e azul em uma localização espacial específica (Figura 3).




Figura 3: Máscaras espaciais para imagens RGB (Gonzalez & Woods, 2009).

Na Figura 4 podem ser vistas diversas representações de uma mesma imagem: em cores (modelo RGB e seus canais individuais), escalas de cinza e preto e branco.



*Figura 4: Representações de uma imagem: a) cores (modelo RGB), b) escalas de cinza, c) preto e branco, d) componente R, e) componente G, f) componente B. Imagem: Lena.jpg (Gonzalez & Woods, 2000).*

Em geral, a imagem pura necessita de transformações que realcem seu conteúdo e propiciem uma extração de informações mais detalhadas e precisas. O processamento digital de imagens realiza estas transformações efetuando a conversão das imagens recém-capturadas em matrizes numéricas e processando-as, utilizando um computador digital para este fim. (Mendes et al., 2014a).

#### **2.4.1 Processamento Digital de Imagens**

Para aplicações de processamento digital de imagens, é utilizado como base o diagrama elaborado por Gonzales e Woods (Figura 5), que descreve os passos fundamentais de um sistema de processamento digital de imagens. Sendo assim são adotados os seguintes passos: domínio do problema, aquisição da imagem, pré-processamento, segmentação, representação e descrição, reconhecimento e interpretação e resultado.




Figura 5: Diagrama do Proc. Digital de Imagens (Gonzalez, Woods, 2000)

### 2.4.2 Aquisição de Imagens

Aquisição de uma imagem é o processo de conversão de uma cena real tridimensional em uma imagem analógica. Segundo (Andrade, 2014), a aquisição tem como função converter uma imagem em uma representação numérica para o processamento digital. Esta etapa compreende dois elementos. O primeiro é um dispositivo físico que produz na saída um sinal elétrico. O segundo é um digitalizador que transforma o sinal analógico em sinal digital. A saída da etapa de aquisição consiste na representação da imagem digital obtida pelo dispositivo físico.

### 2.4.3 Pré-processamento

O pré-processamento consiste no realce da imagem para enfatizar características de interesse ou recuperar imagens que sofreram alguma perda. Esta etapa tem a função de melhorar a qualidade da imagem. O pré-processamento envolve duas categorias principais: métodos que operam no domínio espacial e métodos que operam no domínio da frequência.

Técnicas de processamento no domínio espacial baseiam-se em filtros que manipulam o plano da imagem, enquanto que as técnicas de processamento no domínio da frequência se baseiam em filtros que agem sobre o espectro da imagem.

São exemplos de operações de pré-processamento: melhoramento de contraste, delimitação de regiões de interesse, remoção de ruído, reamostragem dos pixels em outra escala, redimensionamento, entre outras.

### 2.4.4 Segmentação

A segmentação é a extração ou identificação dos objetos contidos na imagem, separando a imagem em regiões. Em outras palavras, a segmentação refere-se à divisão da imagem em regiões de interesse objetivando possibilitar a análise de forma independente. No agrupamento

de regiões são consideradas as características ou propriedades semelhantes entre os pixels, como intensidade e textura, ou a perda de uma característica específica para que as regiões segmentadas possuam aspectos que as diferenciem das demais. (Vale, 2014).

#### **2.4.5 Representação e Descrição**

A saída do estado de segmentação é constituída principalmente por dados em forma de pixels. Desta forma, faz-se necessário converter os dados para uma forma adequada ao processamento computacional, realizando assim a representação mais apropriada para posterior descrição dos dados. Para o reconhecimento do objeto é necessário descrever as propriedades das regiões segmentadas (grupos de pixels). A descrição é muitas vezes apenas um conjunto de dados que são chamados de descritores do objeto. Um método para descrever os dados também deve ser especificado, de forma que as características de interesse também sejam enfatizadas. Este processo, também chamado de seleção de características, procura extrair propriedades que resultem em alguma informação quantitativa de interesse ou que sejam básicas para a discriminação dos objetos. (Vale, 2014).

#### **2.4.6 Reconhecimento e Interpretação**

Reconhecimento é processo de atribuição de um rótulo a um objeto baseado em suas características, traduzidas por seus descritores. A tarefa de interpretação, por outro lado, consiste em atribuir significado a um conjunto de objetos reconhecidos.

#### **2.4.7 Base de conhecimento**

Todas as tarefas das etapas descritas acima pressupõem a existência de um conhecimento sobre o problema a ser resolvido, armazenado em uma base de conhecimento, cujo tamanho e complexidade podem variar enormemente. Idealmente, esta base de conhecimento deveria não somente guiar o funcionamento de cada etapa, mas também permitir a realimentação entre elas. (Filho & Neto, 1999).

### **2.5 Lógica Fuzzy**

A Lógica Fuzzy é baseada na teoria dos Conjuntos Fuzzy. Entretanto, na Lógica *Fuzzy*, uma premissa varia em grau de verdade de “0” a “1”, o que leva a ser parcialmente verdadeira ou parcialmente falsa.

A Lógica Fuzzy (Lógica Difusa ou Lógica Nebulosa), também pode ser definida, como a lógica que suporta os modos de raciocínio que são aproximados ao invés de raciocínio exato é o que estamos naturalmente acostumados a trabalhar.

A força da Lógica Fuzzy deriva da sua habilidade em inferir conclusões e gerar respostas baseadas em informações vagas, ambíguas e qualitativamente incompletas e imprecisas. Neste aspecto, os sistemas de base Fuzzy têm habilidade de raciocinar de forma semelhante à dos humanos. (Cavalcanti et al, 2012)

Proposta por (Zadeh, 1973), a lógica *fuzzy* (ou lógica nebulosa) é uma teoria que se propõe a expressar matematicamente as formulações do pensamento humano em linguagem natural, contudo, diminuir o poder expressivo das mesmas. Definida como um novo caminho para representar a incerteza, a lógica *fuzzy* permite a representação de conceitos vagos, expressos em linguagem natural, tais como, pequeno, quente, bom ruim, dentre outros. (Mendes et al., 2014b).

Com a capacidade de descrição de um modelo matemático para a resolução de um problema decresce à medida que o grau de incerteza do mesmo aumenta, faz-se necessário o surgimento de uma teoria que conseguisse tratar tais problemas sem que as informações importantes se perdessem durante a manipulação de seus dados (Chiu & Park, 1994).

Neste contexto, a teoria *fuzzy* é definida como sendo capaz de combinar a imprecisão associada aos eventos naturais e o poder computacional das máquinas para produzir sistemas de reposta inteligentes, robustos e flexíveis (Cox, 1995).

A lógica *fuzzy* proporciona uma linguagem natural, onde predomina o raciocínio aproximado com proposições imprecisas, utilizando a teoria de conjuntos nebulosos com a principal ferramenta, sendo análoga ao papel da lógica de predicado, utilizando o raciocínio com proposições precisas (Klir & Folger, 1988).

A teoria dos conjuntos *fuzzy* instrumenta analiticamente a lógica *fuzzy*. Utilizando expressões linguísticas a aplicação, define os conjuntos aos quais cada elemento será alocado com diferentes graus de pertinência entre falso e verdadeiro, o que vai de encontro com as separações da lógica clássica.

### 2.5.1 Os conjuntos Fuzzy

Um conjunto *fuzzy* é definido por uma função chamada de função de pertinência.

Cada função de pertinência define um conjunto *fuzzy*,  $A$ , do conjunto universal,  $U$ , através da atribuição de um grau de pertinência,  $\mu_A(x)$ , entre 0 e 1 para cada elemento  $x$  de  $U$ . Este é o grau com o qual  $x$  pertence a  $A$ :

$$\mu_A : \rightarrow [0,1]$$

Um conjunto *fuzzy* pode ser interpretado como a ponte que liga o conceito impreciso

à sua modelagem numérica, atribuindo-se a cada indivíduo no universo um valor entre 0 e 1, que representa o grau de pertinência deste indivíduo ao conjunto *fuzzy*.

A Figura 6 ilustra as componentes de um conjunto *fuzzy*

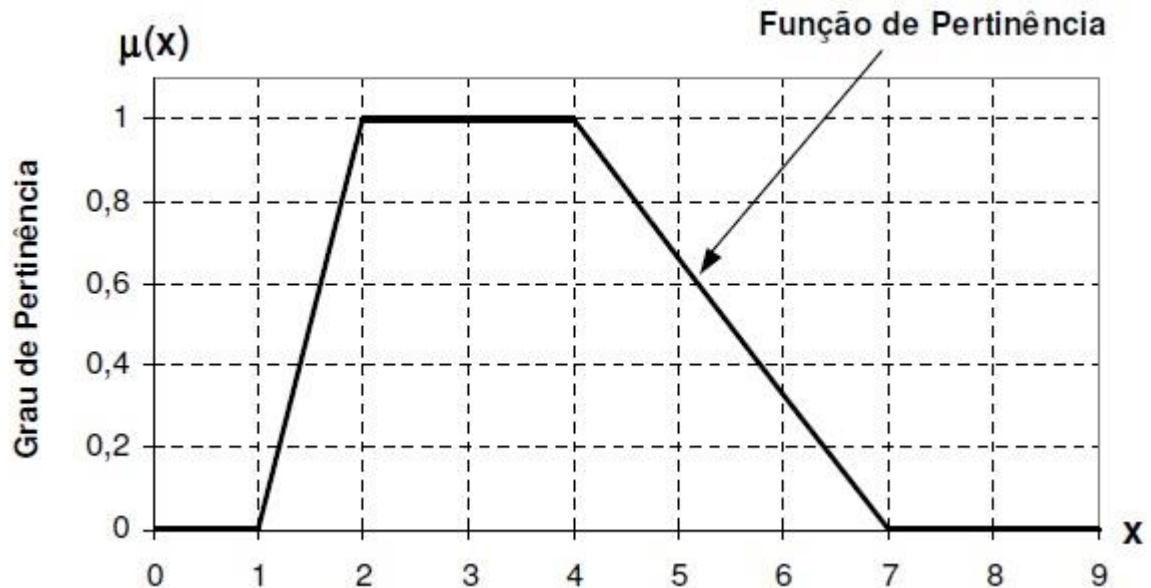


Figura 6: Conjunto Fuzzy

### 2.5.2 Variáveis Linguísticas

Conforme Souza (2010) “Uma variável linguística  $X$  no universo  $U$  é uma variável cujos valores assumidos por ela são subconjuntos *fuzzy* de  $U$ ”. Podemos enxergar a variável linguística sendo o substantivo e seus valores como adjetivo, representado por conjunto Fuzzy. Na Figura 7 fases da vida de uma pessoa que assume valores, jovem, adulto e idoso.




Figura 7: Lógica Fuzzy



### 2.5.3 Funções de pertinência

Cada variável *fuzzy* possui um conjunto de funções  $\mu_x$ ,  $x$  definido no intervalo  $[0,1]$  ao conjunto  $x \in A$ , Inferindo o grau de pertinência de  $x$  no conjunto  $A$ . Isto representa o grau de representação de  $x$  expresso em  $A$ .

- $\mu_A(x) = 1$  indica que  $x$  é completamente compatível com  $A$ ;
- $\mu_A(x) = 0$  indica que  $x$  é completamente incompatível com  $A$ ;
- $\mu_A(x) > 0$  e  $\mu_A(x) < 1$  indica que  $x$  é parcialmente compatível com  $A$ , com grau  $\mu_A(x)$ .

Desta forma a determinação das regras de controle é feita através de um conjunto de regras formado pela união de todas as variáveis reais, de forma a representarem todos os estados das grandezas utilizadas no sistema *fuzzy*.

A Figura 8 exibe os campos de pertinência (*memberships*: baixa, média, alta) de uma dada grandeza, no caso temperatura.




Figura 8: Exemplo de função de pertinência

### 2.5.4 Regras linguísticas

Segundo Vale (2014), a implementação do Sistema de Inferência Fuzzy é modelada através do conhecimento do especialista sobre o problema. Este conhecimento é representado utilizando regras linguísticas.

As representações mais comuns das regras linguísticas são do tipo condição-consequência (se-então) chamados de condições *fuzzy* ou regras *fuzzy*. São exemplos de regras *fuzzy* para investir na bolsa de valores de São Paulo:

- SE (ibovespa) ~ (baixo) ENTÃO (comprar)
- SE (ibovespa) ~ (neutro) ENTÃO (comprar)
- SE (ibovespa) ~ (alto) ENTÃO (não comprar)

Em um sistema *fuzzy* existem muitas regras que utilizam inferência associativa paralela, isto é, são verificadas concomitantemente, ao invés de em série como nos sistemas tradicionais. Neste caso, em um sistema *fuzzy*, a ordem de execução das regras não é importante, exceto quando uma regra depende dos resultados de execução de outras (Kartalopoulos, 1996).

O conjunto de regras linguísticas de um sistema *fuzzy* é comumente chamado de Base de Regras.

### **2.5.5 Sistema de Inferência Fuzzy**

Nos sistemas de inferência *fuzzy*, geralmente, consideram-se entradas não-*fuzzy* (precisas ou crisps); resultantes de observações ou medições (conjunto de dados, por exemplo), que é o caso da grande maioria das aplicações práticas. Em virtude disso, faz-se necessário efetuar uma conversão (fuzzificação) desses dados precisos para os conjuntos *fuzzy* de entrada. Desta forma, a fuzzificação é um mapeamento do domínio da variável crisp de entrada para o domínio *fuzzy*, representando a atribuição de valores linguísticos, descrições vagas ou qualitativas, definidas por funções de pertinência às variáveis de entrada. A fuzzificação é uma espécie de pré-processamento de categorias ou classes de sinais de entrada, a qual reduz o número de valores a serem processados. Uma menor quantidade de valores processados significa que há um menor esforço computacional (Simões and Shaw, 1999).

O sistema de inferência *fuzzy* é um sistema baseado em regras *fuzzy* e possui cinco componentes básicos: a interface de fuzzificação, a base de conhecimento, a base de dados, o procedimento de inferência e a interface de defuzzificação, conforme ilustrado na Figura 9. O sistema de inferência *fuzzy* permite resolver problemas cujas variáveis apresentam imprecisões.

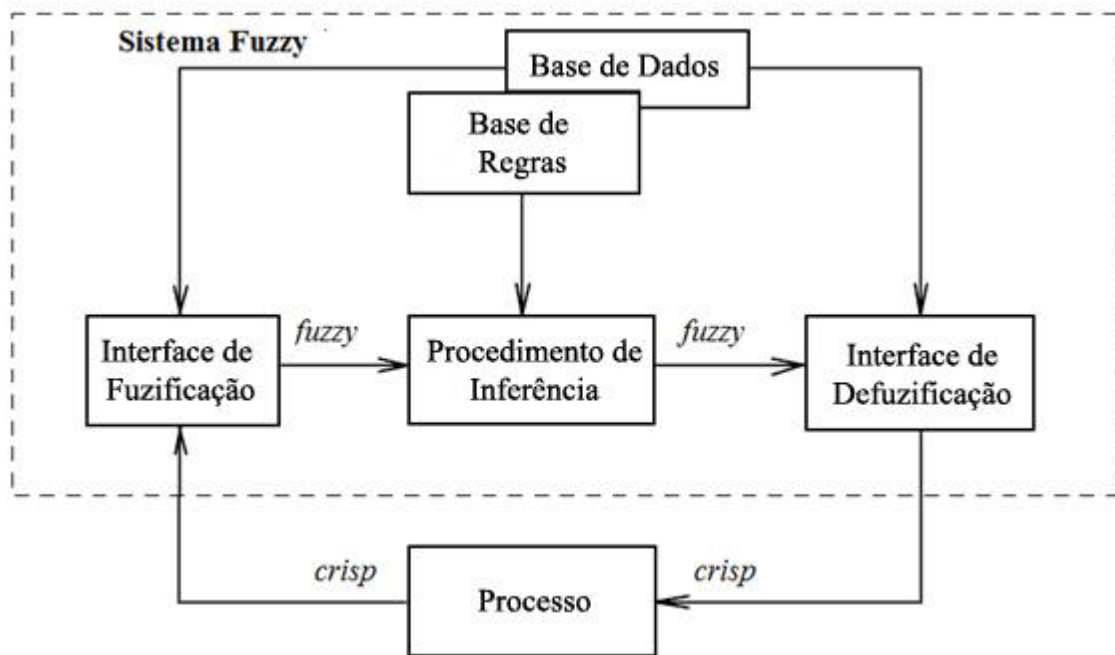


Figura 9: Sistema de Inferência Fuzzy (Adaptado de Leite, 2009).

A Interface de Fuzzificação recebe os valores de entrada, condiciona estes valores aos universos de discurso normalizados e fuzzifica-os, ou seja, transforma-os em elementos do conjunto que possam se tornar instâncias de variáveis linguísticas. Assim, a interface de fuzzificação está diretamente relacionada às variáveis, seus respectivos universos de discurso e os valores que cada variável pode assumir (conjuntos *fuzzy*). Através da interface de fuzzificação os valores observados das variáveis de entrada são associados ao respectivo universo de discurso, permitindo uma avaliação do grau de pertinência aos conjuntos *fuzzy* associados a cada variável. Neste estágio ocorre também a ativação das regras relevantes para uma dada situação. Pinho (1999) cita a necessidade de que especialistas da área estudada sejam consultados durante a atribuição de valores relacionados aos graus de pertinência para cada uma das variáveis em estudo, contribuindo assim para maior precisão nos resultados.

A Base de Conhecimento Fuzzy consiste em uma Base de Regras e uma Base de Dados. A Base de Regras pode ser elaborada por especialistas do domínio em forma de sentenças linguísticas e, definindo a estratégia e o controle do sistema, constitui um aspecto fundamental no seu desempenho. Assim, o desempenho será considerado confiável e satisfatório desde que as regras expressem fiel e consistentemente o seu comportamento. Alternativamente ao uso de especialistas, podem ser usados métodos automáticos de extração de regras a partir de dados numéricos que são particularmente úteis em problemas de classificação. A Base de Dados armazena as definições necessárias sobre as variáveis linguísticas, normalizações e

discretizações dos universos de discurso, as partições *fuzzy* dos espaços de entrada e saída e as definições das funções de pertinência.

O Procedimento de Inferência processa os dados fuzzificados de acordo com as regras *fuzzy* definidas objetivando inferir as ações de controle. Neste componente, as regras são utilizadas para se obter a relação *fuzzy* previamente modelada. Este componente tem muita importância, visto que, como fornece a saída a partir de cada entrada, é dele que depende o sucesso do sistema. Os conjuntos *fuzzy* de entrada, relativos aos antecedentes das regras, e o de saída, referentes aos consequentes, podem ser definidos previamente ou gerados automaticamente a partir dos dados.

A Interface de desfuzzificação processa as saídas *fuzzy* do procedimento anterior em saídas não-*fuzzy* através de um escalamento, de modo a compatibilizar os valores normalizados com os valores dos universos de discurso reais das variáveis. Segundo VonAltrock (1996), a defuzzificação consiste na tradução do resultado linguístico do processo de inferência *fuzzy* em um valor numérico. Em outras palavras, como o algoritmo de controle faz com que o processamento das variáveis linguísticas de entrada resulte em um valor da variável linguística de saída, o processo de defuzzificação consiste em selecionar um valor numérico específico que represente o resultado *fuzzy* da variável de saída produzido pelo conjunto de regras *fuzzy* (Cox, 1995).

### 3 Apresentação das técnicas e etapas desenvolvidas

Neste capítulo são apresentados a contextualização da abordagem desenvolvida, conceitos, aspectos relevantes e contribuições. Para tal, subdivide-se em:

- **Contextualização:** Apresenta a relevância da técnica desenvolvida, sua contextualização e ideal geral.
- **Apresentação da Técnica e Etapas Desenvolvidas:** Apresenta a técnica desenvolvida e suas etapas, aquisição, pré-processamento, segmentação, representação e descrição, reconhecimento e interpretação e base de conhecimento.

#### 3.1 Contextualização

Conforme explicitado no primeiro capítulo, este trabalho tem como objetivo apresentar um conjunto de técnicas inteligentes para segmentação automática de ovos do mosquito do *Aedes Aegypti* e a contagem automática desses ovos através da aquisição das imagens proveniente das armadilhas de oviposição.

Como a entrada do sistema dar-se-á através de imagens digitais e, a partir deste ponto, um conjunto de técnicas e métodos será aplicado a fim de segmentar e classificar os seus elementos de interesse, um prévio detalhamento deverá ser feito para possibilitar o entendimento do contexto no qual o problema está inserido e o correto ajuste das variantes do processo.


Para tal situação, o modelo necessita do conhecimento de um especialista. O especialista deverá ser do contexto onde o problema está inserido, e deve ser conhecedor das especificações e peculiaridades do problema. Ao especialista cabe, contextualização do domínio do problema, detalhamento dos conceitos, descritores de região de interesse e relevância. Esta atuação descenderá na construção da base de conhecimento, e é imprescindível para o correto desempenho das técnicas desenvolvidas. A base de conhecimento intervém no processo em muitos momentos. Aspectos como: técnicas de processamento digital de imagens, histogramas, funções de pertinência e regras de inferência *fuzzy* são intrínsecos e inerentes à base de conhecimento da técnica desenvolvida.

O modelo tem a responsabilidade, de efetuar o processamento da imagem em todos seus aspectos relevantes, interferir neste por meio de inferência a partir da base de conhecimento. Para tanto, executa sequencialmente uma série de etapas com regras especificadas e delimitadas, com objetivos conhecidos e bem definidos, proveniente do domínio do problema

e fortemente ligado à base de conhecimento. Por fim a extração do resultado é dependente de todas estas definições.

### 3.2 Processamento digital de imagens

De acordo com as etapas do processamento digital de imagens, segue na Figura 10 uma representação gráfica da técnica desenvolvida, suas etapas e, destacados em cada uma, os métodos utilizados neste trabalho.



*Figura 10: Diagrama do Proc. Digital de Imagens (Gonzalez, Woods, 2000)b*

#### 3.2.1 Aquisição de imagens

As armadilhas de oviposição (Figura 11), foram confeccionadas com papel toalha reutilizável 21cm x 22cm (Scott duramax) e instaladas em campo por 7 dias. Após este período é realizada coleta das amostras, já as aquisições fotográficas foram realizadas no Centro de Controle de Zoonoses (CCZ), Natal/RN utilizando uma câmera BIOFOCUS acoplada a um microscópio Stemi 305 body (Carl Zeiss Microscopy GmbH), a uma distância média entre 12 a 14 centímetros de altura entre o papel e a lente objetiva. Todas as aquisições fotográficas foram realizadas por um profissional capacitado e integrante do CCZ.




*Figura 11: Modelo de armadilha de oviposição*

### **3.2.2 Pré-processamento**

O pré-processamento tem como objetivo realçar a imagem para aumentar as chances de sucesso dos processos seguintes. Dessa forma, a etapa de pré-processamento destaca as regiões de interesse a partir de um limiar obtido de acordo com o histograma da imagem (limiarização). As etapas de pré-processamento neste trabalho e descrito no algoritmo a seguir:

- Passo 1: Transformar a imagem recebida em tons de cinza.
- Passo 2: Extrair o histograma.
- Passo 3: Calcular as diferenças entre os pontos do histograma, descartando os pontos subsequentes que são menores que o anterior.
- Passo 4: Criar um vetor de distancias entre cada par de pontos subsequente e anterior considerando faixas de 20 tons de cinza.
- Passo 5: Calcular as diferenças entre as faixas de 20 tons de cinza, ordenando para encontrar a maior diferença entre as faixas (subida abrupta da curva do histograma) adquirindo o ponto de corte.
- Passo 6: Dividir o ponto de corte por 1.5 para retirar sobras que ficam em algumas imagens.

Esse limiar será utilizado na etapa seguinte de segmentação dos objetos de interesse. A Figura 12 exemplifica a etapa do pré-processamento.



*Figura 12: Pré-processamento*

### 3.2.3 Segmentação


A segmentação é o processo que divide uma imagem de entrada em partes ou objetos constituintes (Gonzalez, Woods, 2000). Nessa etapa do processo, as regiões de interesse são segmentadas a partir das imagens pré-processadas onde cada pequena região de interesse se tornará uma nova imagem. Segundo (Mendes et al., 2014b), a precisão da fase de segmentação poderá determinar o sucesso ou falha dos procedimentos de análise de imagem.

Após a limiarização, são aplicados os operadores morfológicos, separando as regiões de interesse, obtendo uma imagem cujas características são fundo preto e regiões de interesse em branco. Em seguida os objetos serão separados individualmente para extração de suas características. As etapas de segmentação neste trabalho é descrito no algoritmo a seguir:

- Passo 1: Recebe a imagem limiarizada.
- Passo 2: Realiza uma inversão de cor, fundo preto e objeto de interesse em branco.
- Passo 3: Realiza um recorte em caixa para cada objeto de interesse.
- Passo 4: Cria um diretório com todos os objetos encontrados.

A etapa de segmentação está exemplificada na Figura 13.






*Figura 13: Segmentação de imagem com ovos*

### 3.2.4 Representação e descrição


Após a etapa de segmentação ocorre a extração de características dos objetos segmentados. A etapa de segmentação e descrição consiste em extrair características dos ovos para que possam ser utilizados na classificação dos objetos ovos e não ovos. A cada área de interesse individual obtida como saída da segmentação é associada um vetor de características utilizando os descritores de área, convexidade, forma, perímetro e diâmetro conforme detalhamento a seguir:

O descritor de área é o cálculo em pixel da região ocupada pelo objeto que foi segmentado (Figura 14).




*Figura 14 Descritor de área*

Convexidade criar um objeto convexo na imagem segmentada, e contabilizar os pixels que pertencem ao objeto convexo e não pertencem a imagem (Figura 15).




*Figura 15* *Descriptor de convexidade*

O descritor de forma detecta e contabiliza a quantidade de curvas que a imagem segmentada possui (Figura 16.)




*Figura 16* *Descriptor de forma*

O Descritor de diâmetro é a medida em percentual do menor diâmetro pelo maior do objeto segmentado (Figura 17).



*Figura 17* *Descritor de diâmetro*

O descritor de perímetro é a medida da quantidade de contorno que o objeto segmentado apresenta. (Figura 18)



*Figura 18 Descritor de perímetro*

### 3.3 Sistema de Inferência *Fuzzy*

O SIF utiliza como variáveis linguísticas os descritores definidos nas fases anteriores do processo, conforme a ilustração da Tabela 2.

A partir da obtenção dos valores das características morfológicas dos ovos, torna-se possível a definição das faixas de valores em que características exclusivas dos ovos podem ser encontradas, além de ser possível observar o comportamento proporcional entre as características da área, perímetro, forma, convexidade e diâmetro. Essas faixas de valores são criadas com o intuito de serem utilizadas como parâmetro de execução do sistema *fuzzy* (Tabela 1).

*Tabela 1: Variáveis Linguísticas*

Variável linguística	Pequena		Média		Grande	
	Início	Fim	Início	Fim	Início	Fim
Área	0	1400	-	-	900	5000
Forma	0	23	15	45	38	60
Convexidade	0	60	38	308.8	280	450
Diâmetro	0	23	18	60	50	100
Perímetro	20	180	-	-	160	304

Tabela 2: Exemplo de base de dados

Id	Área	Convexidade	Perímetro	Forma	Diâmetro	Fuzzy
1	174	5	60	4	39,4146	0
2	37	0	24	4	100	0
3	112	0	44	3	87,7338	0
4	37	0	24	4	100	0
5	2807	132	250	31	27,0994	1
6	188	16	58	9	82,8029	0
7	68	0	36	4	84,9199	0
8	2675	56	250	23	25,4442	1
9	111	1	43	2	77,3032	0
10	2546	424	208	34	93,9358	0
11	52	1	30	4	76,796	0
12	51	0	28	2	80,4048	0

### 3.4 Processo de Fuzzificação

O processo de fuzzificação trata dos valores extraídos das características do objeto de estudo (ovo, não ovo) nas imagens e os organizam em conjuntos nebulosos que representarão as funções de pertinência das variáveis linguísticas definidas(Figura 19).




Figura 19 Modelo de fuzzyzificação das variáveis linguísticas

A cada variável nebulosa é atribuído conjuntos nebulosos que correspondem às funções de pertinência: “Grande”, ”Média” ou “Pequena”. Tais funções de pertinência são definidas de acordo com a função trapezoidal para as variáveis linguísticas: Área, Forma, Perímetro, Convexidade e Diâmetro. A escolha da função trapezoidal dá-se, devido ao fato de existirem valores para máximos e mínimos bem definidos(Figura 20).

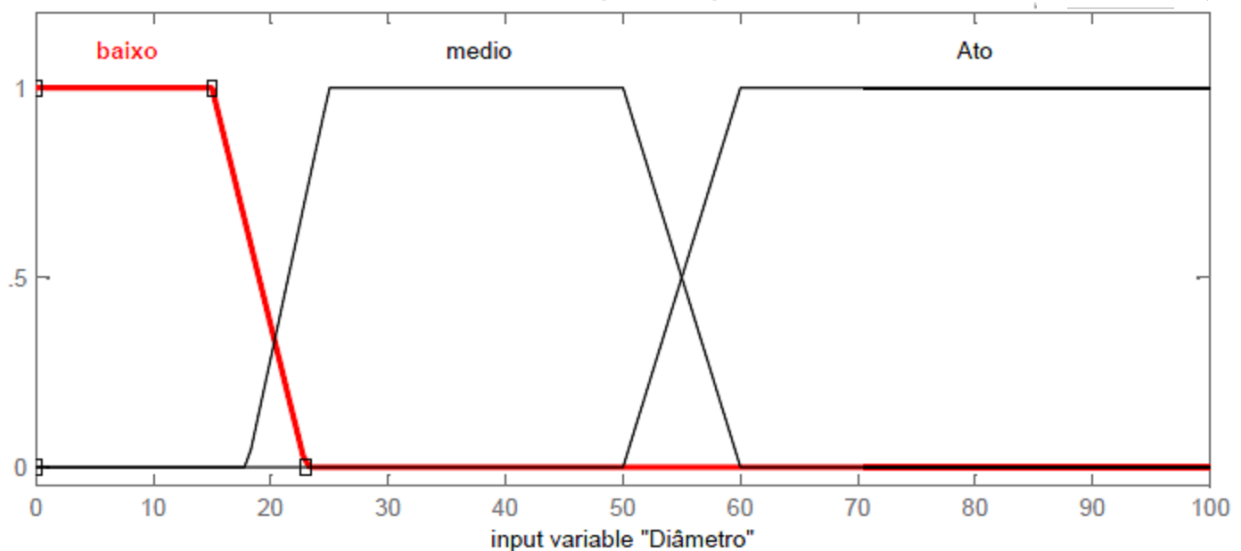


Figura 20 Exemplo de função trapezoidal para variável linguística Diâmetro

A função de pertinência denominada "Grande" de cada variável de entrada sempre retrata a mesma ideia, por exemplo, no caso da variável Área, indica que há um intervalo de valores que admitirá a certeza que é a área de um ovo do mosquito *Aedes aegypti* e outro intervalo com valores acima ou abaixo de um determinado limiar que representam a pertinência parcial neste conjunto de Área.

Já a função de pertinência denominada "Pequena", a cada variável de entrada esta retratará a mesma ideia, por exemplo, no caso da variável Área, indica que há um intervalo de valores que reconhecerá esta área como sendo não área de um ovo do mosquito *Aedes aegypti* e outro intervalo com valores acima ou abaixo de um determinado limiar que representam a pertinência parcial neste conjunto de Área.

### 3.5 Variáveis de saída

O importante nos conjuntos nebulosos das variáveis de saída é que os mesmos possuam todos os graus de pertinência possíveis, por isso, selecionou-se a forma triangular e mesmo tamanho para cada saída (Figura 21).

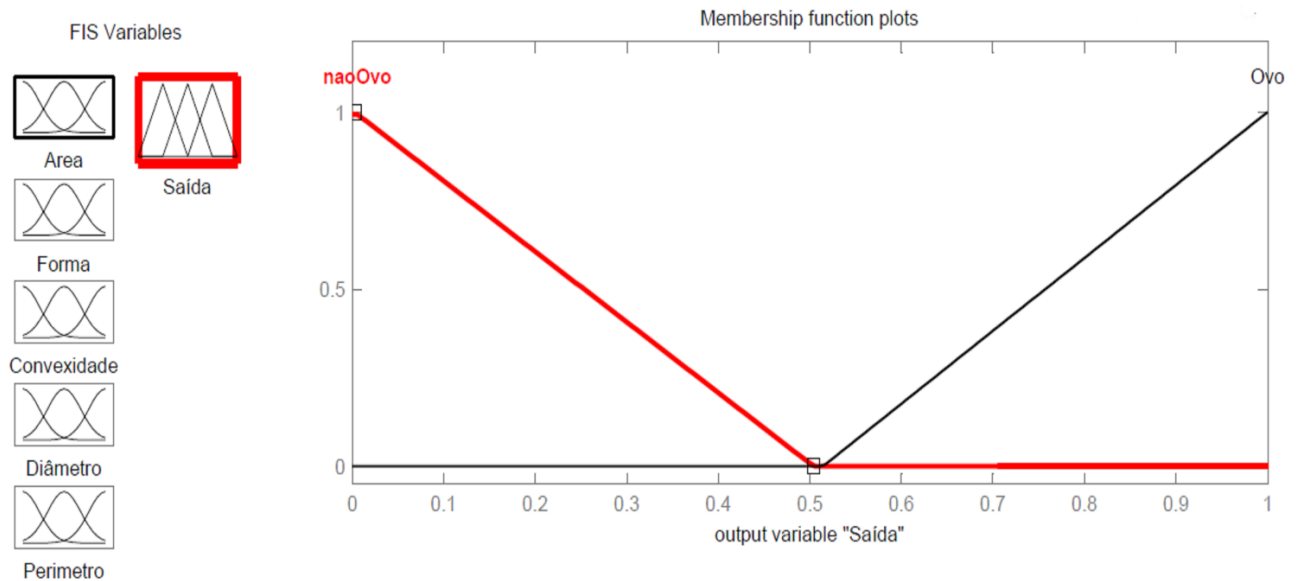


Figura 21: Saída do SIF

### 3.6 Implementações das regras Fuzzy

As regras *fuzzy* foram geradas de forma a relacionar os diversos resultados obtidos com as combinações de bandas, sendo definidas da seguinte forma:

Regra 1: Se área é grande e forma é média e convexidade é média e diâmetro médio e perímetro é grande, então, (a saída é ovo) (1)

Regra 2 Se área é grande e forma é média e convexidade é alta e diâmetro é médio e perímetro é grande, então, (a saída não é ovo) (1).

Regra 3: Se área é grande e forma é grande e convexidade não é alta e diâmetro é alta e perímetro é grande, então, (a saída não é ovo)(1)

Regra 4: Se área é pequena e forma não é média e convexidade não é média e diâmetro médio e perímetro é grande, então, (a saída não é ovo) (1).

### 3.7 Processo de Defuzzificação

As saídas resultantes dos conjuntos *fuzzy* são defuzzificados pelo método da Média dos Máximos (MoM). Este método produz uma média ponderada dos valores das variáveis linguísticas. Então o sistema retorna o valor defuzzificado e através do mesmo é efetuada uma

verificação onde resulta se variável de saída é ou não um ovo, se a pertinência do conjunto *fuzzy* for maior que 0,5 o sistema classifica o objeto como ovo, caso contrário como não ovo, conforme Figura 22.

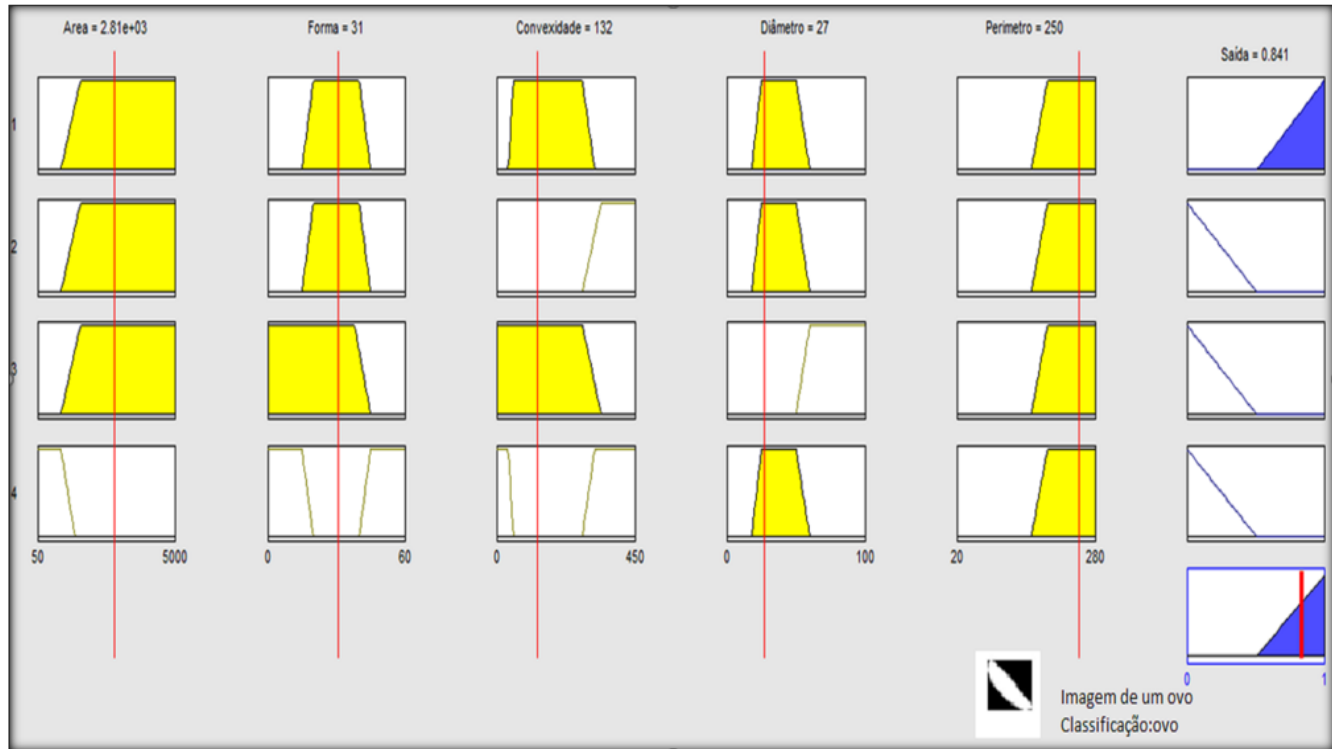


Figura 22: Classificação do sistema de inferência.

## 4 Análise de resultados

Neste capítulo são apresentados os experimentos realizados, os resultados e discussões. Para tal, subdivide-se em:

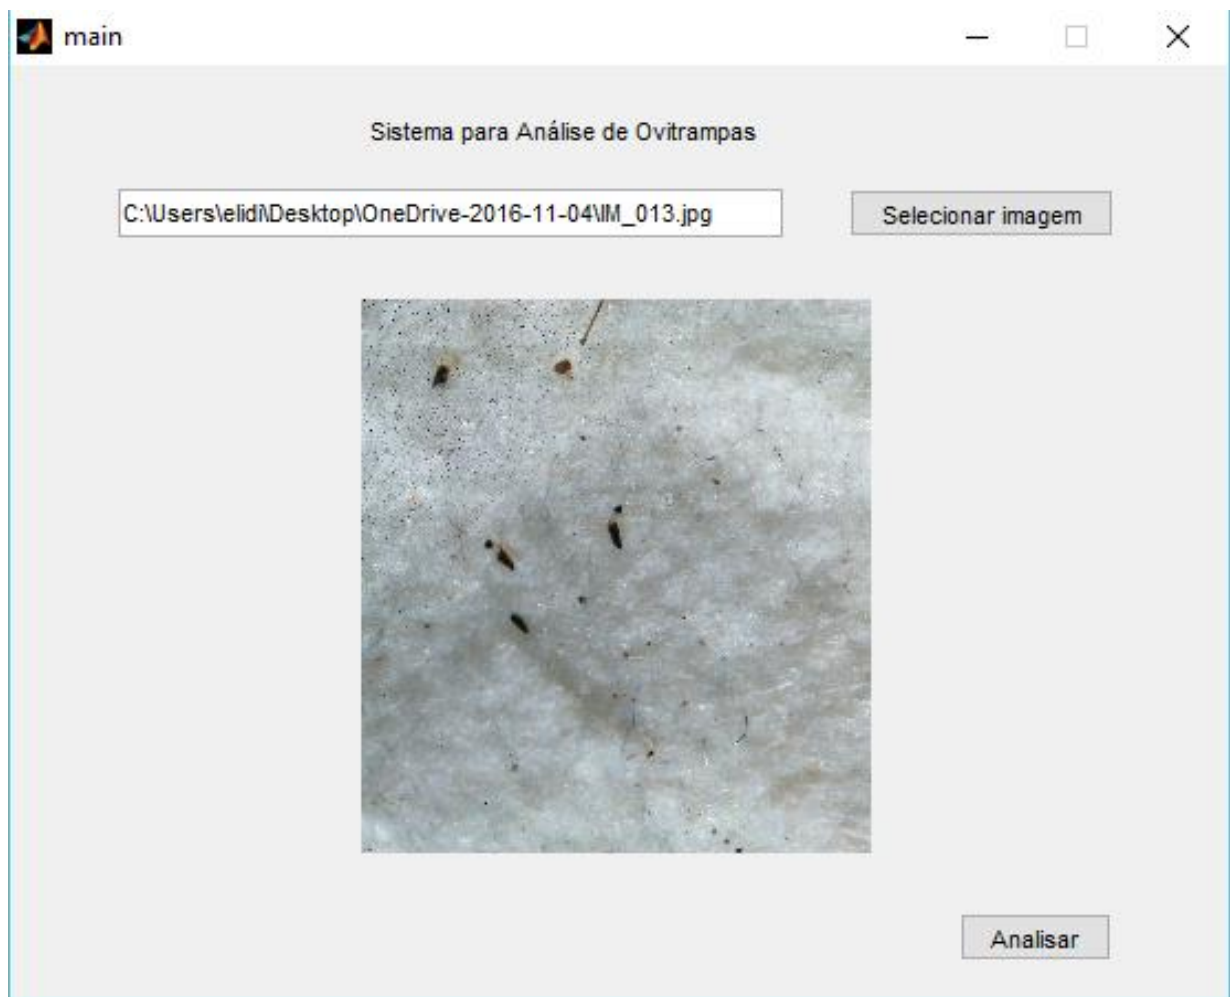
- **Experimentos:** Apresenta as análises feitas após a aplicação das técnicas desenvolvidas nas imagens previamente elaboradas.
- **Resultados:** Apresenta os índices de *Gold Standards* e acurácia encontrados na classificação e contagem dos componentes dos ovos do Aedes.
- **Discussões:** Análise dos resultados obtidos.

### 4.1 Experimentos

Foram analisadas 206 imagens das armadilhas de oviposição contendo ovos do Aedes e outros objetos provenientes do ambiente onde foram dispostas as armadilhas totalizando 7772 objetos, dentre as quais foram contabilizados 386 ovos do mosquito. Estas imagens foram processadas de acordo com as técnicas previamente definidas neste trabalho.

Para avaliar a técnica desenvolvida, foi desenvolvido um sistema computacional utilizando o software MathWorks Matlab R2014a (Mathworks, 2014) contendo os Sistemas de Inferência *Fuzzy*. O sistema consiste em um algoritmo que processa o banco de imagens para que os percentuais possam ser calculados para cada imagem processado. Também foram desenvolvidas uma interface para processamento das imagens e visualização dos resultados. Na tela inicial do sistema as imagem são selecionada e processadas (Figura 23).





*Figura 23: Tela inicial Seleção e processamento das imagens*

Após as imagens serem selecionadas e processadas, o sistema realiza a classificação de cada objeto como ovos e não ovo e contabiliza os objetos que são ovos(Figura 24).

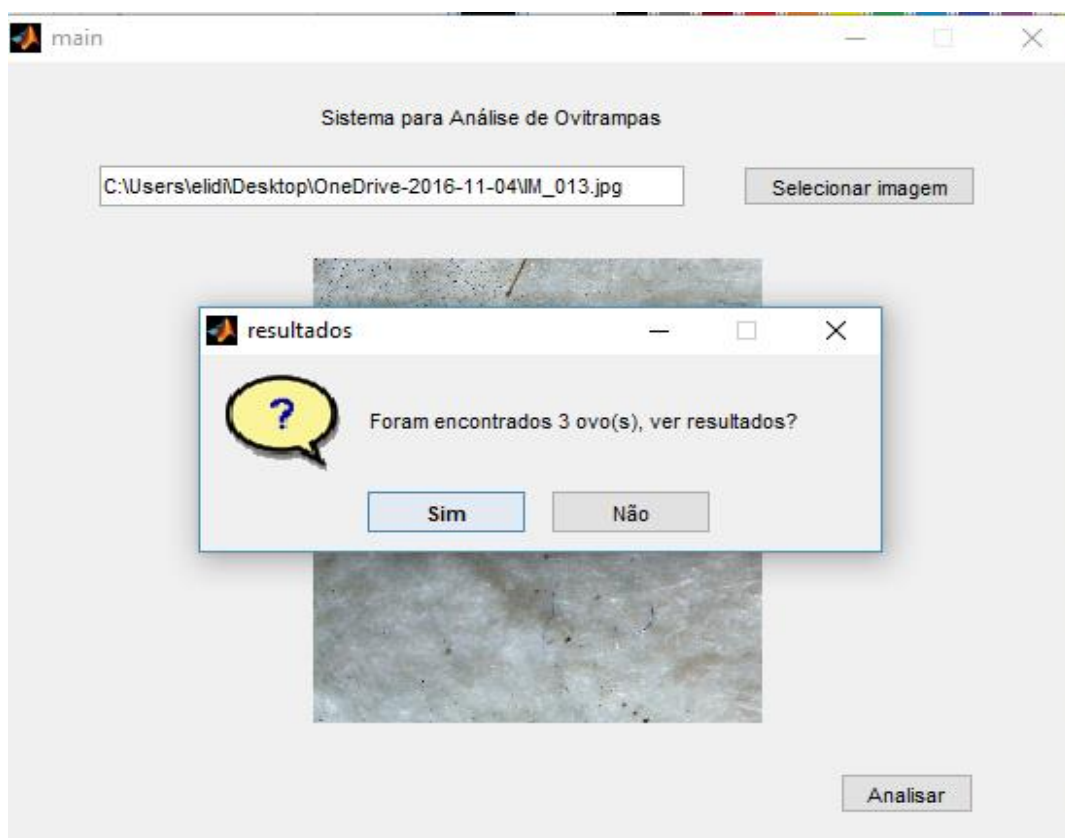


Figura 24: Resultado da classificação e contagem dos objetos das imagens.

## 4.2 Resultados

Os resultados são apresentados para segmentação, classificação e contagem dos ovos do *Aedes aegypti*.

Todas as imagens foram processadas e os seus resultados na etapa de segmentação foram comparadas com as segmentações manuais, para os cálculos dos índices de Gold Standards (Vale, 2014). Considerando que os componentes foram identificados em 100% dos casos, a análise feita avaliou a área encontrada para cada componente pela segmentação automática comparada com a área segmentada manualmente por especialistas. As métricas consideradas para os índices de *Gold Standards* (Tabela 3) foram Verdadeiro Positivo (TP), Falso Positivo (FP), Verdadeiro Negativo (NT) e Falso Negativo (NF) (Tabela 4). Além dessas métricas, o índice de Acurácia (AC) foi calculado conforme Aghajari e Damayanti (2011), de acordo com a expressão.

$$AC = ((TP + TN) / (TP + FN + TN + FP)) * 100$$

Tabela 3: Matriz de Confusão

Teste	Ovos	Não Ovos
<b>Resultado positivo</b>	379	17
<b>Resultado Negativo</b>	65	7311
<b>Total (Positivo +Negativo)</b>	444	7328

Tabela 4: Resultados da classificação do Sistema

Componente	TP%	TN%	FN%	FP%	Acurácia
<b>Ovos</b>	85,36	99,76	14,64	0,24	98,94

Após a segmentação e a extração dos descritores, os objetos foram classificados, utilizando o Sistema de Inferência *Fuzzy* proposto, em ovos e não ovos e contabilizado os objetos classificados como ovos. Os resultados obtidos pelo classificador *fuzzy* desenvolvido neste trabalho podem ser vistos na da Tabela 3.

Os parâmetros usados para a análise dos resultados do SIF são: Sensibilidade (taxa de verdadeiros positivos) a capacidade do sistema em predizer corretamente a condição para casos que realmente a têm. Especificidade (taxa de verdadeiros negativos) a capacidade do sistema em predizer corretamente a ausência da condição para casos que realmente não a têm. Valor preditivo positivo (VPP) indica qual a probabilidade do sistema com testar positivo e realmente tenha a condição. Valor preditivo negativo (VPN) indica qual a probabilidade de o sistema testar negativo realmente não tenha a condição. Coeficiente de correlação de Matthews (MCC) é uma medida de qualidade de duas classificações binárias que pode ser usada mesmo se as classes possuem tamanhos bastante diferentes. Retorna um valor entre (-1) e (+1), em que um coeficiente de (+1) representa uma predição perfeita, (0) representa uma predição aleatória media, e (-1) uma predição inversa (Zhu, 2010). Esses parâmetros foram calculados de acordo com as expressões.

$$1. \text{ Sensibilidade} = \frac{TP}{(TP+FN)}$$

$$2. \text{ Especificidade} = \frac{TN}{(TN+FP)}$$

$$\begin{aligned}
3. \quad VPP &= \frac{TP}{(TP+FP)} \\
4. \quad VPN &= \frac{TN}{(TN+FN)} \\
5. \quad MCC &= \frac{(TP*TN)-(FP*FN)}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}
\end{aligned}$$

O resultado dos cálculos destes parâmetros, para o sistema proposto nesse trabalho, está na Tabela 5.

*Tabela 5: Resultado da Classificação e Contagem do Sistema*

SIF	Sensibilidade	Especificidade	VPP	VPN	MCC	Acurácia
	85,4%	99,8%	95,7%	99,1%	0,9	98,94%

Face aos resultados obtidos, concluímos que o método de classificação e contagem pelo sistema de inferência *fuzzy*, apresenta resultados apreciáveis quanto à classificação e contagem de ovos do *Aedes aegypti*.

### 4.3 Discussões

Um grupo de imagens foi processado neste trabalho, objetivando a segmentação automática, classificação e contagem dos ovos do *Aedes aegypti*. Taxas significativas de TP e TN foram obtidas, indicando os percentuais de sucesso na identificação da presença e ausência, respectivamente, dos componentes na amostra, enquanto que as taxas de FP e FN indicaram os percentuais de erro na identificação e da ausência dos componentes, quando em comparação com as respectivas segmentações manuais.

As discussões são apresentadas separadamente para segmentação e classificação e contagem.

#### 4.3.1 Segmentação

As análises das 206 imagens, provenientes das armadilhas de oviposição, mostraram altos índices de precisão na segmentação desses componentes, demonstrando um alto nível de relevância para a porcentagem de acertos em relação a erros obtidos na segmentação. Para taxa de erros do sistema, foi proveniente das semelhanças das características individuais de um ovo do *Aedes* e de objetos oriundos do meio onde foram instaladas as armadilhas de oviposição, como podemos ver na Figura 25.




Figura 25: Imagem segmenta Identificação de falsos positivos.

Observando os valores das funções pertinência na base de dados das variáveis linguísticas da Figura 25, a classificação do objeto como falso positivo é em função dos valores serem próximos das faixas definidas para objetos ovos.(Figura 26).

Área	Convexidade	Perímetro	Forma	Diâmetro	Fuzzy
76	3	38	4	61,89226	0
729	68	118	18	35,18002	0
234	10	63	6	76,8229	0
129	6	49	6	54,29581	0
464	17	82	9	69,53093	0
49	0	28	2	91,21457	0
783	130	125	16	33,85087	0
97	1	40	2	81,2629	0
203	8	59	5	66,28807	0
2069	72	199	26	28,38372	1
1554	150	162	20	35,16038	1
172	13	56	9	72,53183	0
323	82	89	13	49,52206	0
37	0	24	4	100	0
70	2	34	2	90,65005	0
705	77	108	18	70,1679	0
5000	450	280	55	75,40218	0
1595	187	167	23	67,615	0
44	0	26	2	89,42138	0
501	43	94	14	47,92882	0



 Verdadeiro positivo  
 Falso positivo

Figura 26: Resultado da classificação do sistema para falso positivo

Já os valores de FN foram provenientes principalmente da incapacidade do sistema em segmentar ovos colados ou outros objetos juntos a um ovo, elevando os valores de convexidade, como podemos ver, na Figura 27 .



Figura 27: Falso Negativo: ovos colados.

Quando o sistema segmenta objetos colados a convexidade do objeto segmentado é alta e o sistema de inferência o classifica como não ovo(Figura 28).

Área	Convexidade	Perímetro	Forma	Diâmetro	Fuzzy	
37	0	24	4	100	0	
120	1	44	2	83,58284	0	
4651	450	280	60	39,36521	0	Falso negativo
72	0	34	2	60,93809	0	
75	1	36	4	79,1386	0	
208	19	61	7	46,95604	0	
2038	99	225	22	24,27112	1	Verdadeiro positivo
652	98	112	19	49,68979	0	
4725	450	280	53	72,75291	0	Falso negativo
267	45	75	7	54,02297	0	
37	0	24	4	100	0	
65	2	34	4	72,99939	0	
37	0	24	4	100	0	
141	5	51	6	79,15753	0	
37	0	24	4	100	0	

Figura 28: Classificação de objetos como falso negativo.

As taxas de TP, TN, FP, FN e AC obtidas para a segmentação demonstram a capacidade do método para obter êxito no que se propôs a realizar, como pode ser observado na Figura 29.

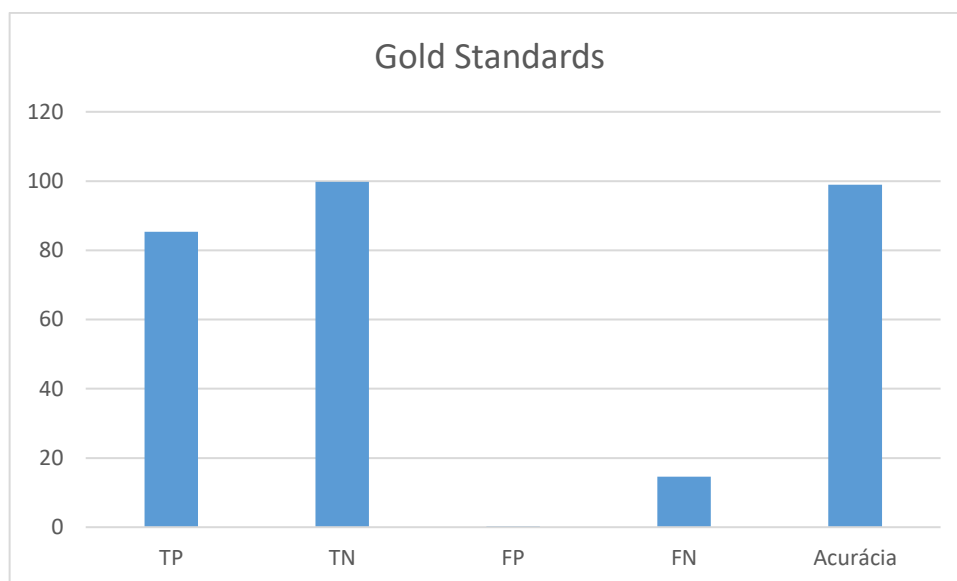


Figura 29: Os valores do *Gold Standards* estão em porcentagem(%)

#### 4.3.2 Classificação e contagem

Analisando as 206 imagens contendo ovos, provenientes das armadilhas de oviposição, foram encontrados percentuais de acurácia de 98,94% sensibilidade de 85,4%, especificidade de 99,8%, VPP de 95,7%, VPN 99,1% e MCC 0,9. Estes altos índices resultantes demonstraram uma capacidade relevante do método para a classificação e contagem dos ovos pelo sistema de inferência.

## 5 Conclusão

Neste capítulo são apresentados as conclusões, as contribuições e os trabalhos futuros.

- **Conclusões:** Apresenta um fechamento do trabalho contendo as conclusões a partir dos objetivos específicos proposto anteriormente.
- **Trabalhos Futuros:** Apresenta as perspectivas para trabalhos futuros.

### 5.1 Conclusões

A detecção e contagem dos ovos do *Aedes aegypti* é um importante elemento na área de vigilância epidemiológica da prefeitura de Natal e possibilita ao profissional desta área, fazer uma análise juntamente com outros parâmetros, quais áreas da cidade serão realizadas ações de prevenção e controle deste mosquito. Faz-se necessário que sistemas computacionais auxiliem neste trabalho oferecendo ferramentas de apoio que diminuam o custo e aumentem a precisão. Tais ferramentas devem ter uma inteligência incorporada que contenha o conhecimento especializado necessário às tarefas decorrentes destas análises.

Este trabalho apresentou um conjunto de técnicas utilizando sistema de inferência *Fuzzy* capaz de segmentar, em uma imagem de oviposição áreas de interesse, classifica-os como ovos ou não ovos e contabilizando-os.

Visando aumentar a precisão das análises, as técnicas foram desenvolvidas para que a segmentação fosse automática e adaptativa para que, a cada imagem, um mesmo conceito pudesse ser automaticamente adaptado ao novo contexto sem a interferência do usuário. Desta forma, o conhecimento especialista foi incorporado nas bases de conhecimento agregando valor às técnicas e aumentando as taxas de sucesso nos experimentos. Com este conhecimento foram definidas funções de pertinência *fuzzy* capazes de realizar as tarefas de segmentação e classificação a partir de um olhar especializado.

Além disso, um banco de imagens real foi construído com o auxílio dos especialistas da área de epidemiologia da prefeitura de Natal e alguns alunos da Disciplina de Projetos aplicado II do curso de Tecnologia em Análise e Desenvolvimento de Sistema da Escola Agrícola de Jundiá (EAJ)/UFRN.

Os resultados encontrados foram comparados às segmentações manuais, também validadas por especialistas, de forma que pudessem expressar valores corretos e não perspectivas de sucesso. Os experimentos mostraram resultados expressivos, aumentando o campo de pesquisa na área e contribuindo com a inclusão uma nova abordagem *fuzzy* para o problema de segmentação e contagem dos ovos do *Aedes aegypti*.



## 5.2 Trabalhos Futuros

Como perspectivas de trabalhos futuros, pode-se citar:

- Disponibilização e ampliação do banco de imagens para pesquisas públicas.
- Melhorar as técnicas de segmentação das imagens, para diminuir a taxa de falsos positivos.
- Desenvolver um sistema de inteligência artificial com redes neurais artificiais, que a partir da contagem dos ovos, de índices de positividade (IPO) e índice de densidade de ovos (IDO), faça o mapeamento das regiões da cidade de Natal onde serão realizadas ações de prevenção e controle do vetor transmissor do Aedes, antes que as pessoas dessa região venham a adoecer.
- Desenvolvimento um sistema mobile que faça a captura das imagens dos ovos do mosquito enloco, e as envie para o sistema que realiza a previsão de incidência das doenças do Aedes.

## 6 Referências

- Aghajari, E.; gharpure, M.; Associate, D. **Incorporating FCM and Back Propagation Neural Network for Image Segmentation. International Journal of Computer &, n. Viii, p. 121–126, 2011.**
- Andrade, A. O. **Sistema de Contagem com Morfologia Matemática Fuzzy. 2014.**
- Boaventura, A. G. **Números Fuzzy em Processamento de Imagens Digitais e Suas Aplicações na Detecção de Bordas. 2010.**
- Carone, B.A. M; Pereira.R. **Sistema de Software para Contagem Automática de Pessoas em Tempo Real. 2012.**
- Cavalcanti.F.H.J. **Lógica Fuzzy Aplicada as Engenharias.2012.**
- Communitor,**Georreferenciamento**.Disponivelem:<<http://www.communitor.com.br/georreferenciamento/>> Acessa em 11 de Outubro de 2016.
- Chiu, C; Park, C.S. (1994) **Fuzzy cash flow analysis using present worth criterion. The Engineering Economist, Vol 39(2): 113-138**
- Cox, E. (1995) **Fuzzy logic for business and industry. Massachussetts: Charles River Media Inc.**
- Dias, A. **Análise espacial aplicada à delimitação de áreas úmidas da planície de inundação do médio Araguaia. 2014.**
- E Aghajari,E.; Damayanti,G - **International Journal of Computer and Communication , 2011**
- Feitosa, N. **Sistema de contagem automática de ovos do *Aedes aegypti* a partir de Processamento de Imagens das palhetas de Ovitampas. 2015.**
- Filho, O. M.; Neto, H. V. **Processamento Digital de Imagens. Rio de Janeiro: Brasport,1999.**
- Ferreira, C. S. **Implementação do algoritmo de subtração de fundo para detecção de objetos em movimento, usando sistemas reconfiguráveis. 2012.**

- Gonzalez, R. C.; Woods, R. E (2000) **Processamento Digital de Imagens**. 2ª edição, Editora Edgard Blücher, São Paulo.
- Kartalopoulos, Stamatios V. **Optimal parallel processor architecture for real time multitasking**. U.S. Patent n. 5,590,323, 31 dez. 1996.
- Klir, George J.; Folger, Tina A. **Fuzzy sets, uncertainty, and information**. 1988.
- Lucas, Carlo Foletto. **Técnicas de segmentação e classificação de imagens em exames de ressonância magnética nuclear**. Revista da Graduação, v. 7, n. 2.
- Vale, A. et al. **Técnica para Segmentação Automática de Imagens Microscópicas de Componentes Sanguíneos e Classificação Diferencial de Leucócitos Baseada em Lógica Fuzzy**. 2014.
- Neto, C. (2009). **Previsão de incidência de dengue nas cidades Brasileiras através de inteligência artificial**.
- Portela, N. M.(2009) **Contagem automática de ovos de aedes aegypti em imagens de ovitrampas**.
- Santos, A. P. D. O. **Desenvolvimento de Descritores de Imagens para Reconhecimento de Padrões de Plantas Invasoras (Folhas Largas e Folhas Estreitas)**. p. 203, 2009.
- Shaw, I. S.; Simões, M. G. **Fuzzy Control and Modeling**. São Paulo: FAPESP, Editora Edgard Blücher LTDA, 1999.
- Silva, B. R. DE A. **Sistema de contagem automática de objetos utilizando processamento digital de imagens em dispositivos móveis**. 2014.
- Souza, L. P. **Análise morfológica de imagens e classificação de aberrações cromossômicas por meio de lógica fuzzy**. 2011.
- Zadeh, L.A. (1973). **Outline of a New Approach to the Analysis of Complex Systems and Decision Processes**. IEEE Trans. on Systems Man & Cybernetics, Vol.3: 28-44.
- Zhu, W.; ZENG, N.; WANG, N. **Sensitivity , Specificity , Accuracy , Associated Confidence Interval and ROC Analysis with Practical SAS ® Implementations K & L consulting services , Inc , Fort Washington , PA Octagon Research Solutions , Wayne. NESUG : Health Care and Life Sciences**, p. 1–9, 2010.

## 6.1 Apêndice

Amostra do banco de imagens utilizado no experimento.



Figura 30 Amostra 1: Imagem com quatro ovos



Figura 31 Amostra 2: Imagem com três ovos






Figura 32 Amostra 3: Imagem com dez ovos



Figura 33 Amostra 4: Imagem com dez ovos



Figura 34 Amostra 5: Imagem com quatro ovos